

Báo cáo cuối kì

Khoa Toán - Cơ - Tin học
Trường Đại học Khoa học Tự nhiên
Đại học Quốc gia Hà Nội

Ngày 10 tháng 1 năm 2026

- **Phan Nguyễn Mạnh Cường** — Phụ trách phân tích và xử lý dữ liệu.
- **Nguyễn Tiến Đạt** — Xây dựng mô hình Softmax Regression
- **Hồ Trọng Hiếu** — Xây dựng mô hình K-nn

- **Giới thiệu bài toán:** Đặt vấn đề, bối cảnh. Xác định mục tiêu và tầm quan trọng của bài toán.
- **Xử lý dữ liệu:** Mô tả, làm sạch, chuẩn hóa.
- **Các phương pháp và mô hình huấn luyện:**
- **Kết quả thực nghiệm:** Trình bày kết quả của từng mô hình.
- **Định hướng phát triển:** Chỉ ra các hạn chế. Đề xuất hướng cải thiện.

Giới thiệu bài toán

Tổng quan về bộ dữ liệu

- Tập dữ liệu gồm 100.000 quan sát và 28 thuộc tính, mô tả thông tin tài chính, hành vi tín dụng và một số thông tin cá nhân của khách hàng.
- Có 18 thuộc tính dạng số(numeric) và 10 thuộc tính dạng đối tượng(object)
- Trường mục tiêu là cột phân loại điểm tín dụng (Credit Score) của từng cá nhân để đánh giá mức độ tin cậy của từng cụm khách hàng.
- Có các trường Id, Customer Id , Name, SSN, Type of loan chỉ mang ý nghĩa định danh nên sẽ bị loại bỏ

Ta chỉ thao tác trên 23 trường còn lại

Giới thiệu bài toán

Phân tích bộ dữ liệu

Sử dụng các chỉ số thống kê để đánh giá tính hợp lệ của dữ liệu

	Monthly_Inhand_Salary	Num_Bank_Accounts	Num_Credit_Card	Interest_Rate	Delay_from_due_date	Num_Credit_Inquiries	Credit_Utilization_Ratio
count	84998.000000	100000.000000	100000.000000	100000.000000	100000.000000	98035.000000	100000.000000
mean	4194.170850	17.091280	22.47443	72.466040	21.068780	27.754251	32.285173
std	3183.686167	117.404834	129.05741	466.422621	14.860104	193.177339	5.116875
min	303.645417	-1.000000	0.00000	1.000000	-5.000000	0.000000	20.000000
25%	1625.568229	3.000000	4.00000	8.000000	10.000000	3.000000	28.052567
50%	3093.745000	6.000000	5.00000	13.000000	18.000000	6.000000	32.305784
75%	5957.448333	7.000000	7.00000	20.000000	28.000000	9.000000	36.496663
max	15204.633333	1798.000000	1499.00000	5797.000000	67.000000	2597.000000	50.000000

Hình: Thông số thống kê của một số thuộc tính trong bộ dữ liệu

- Tập dữ liệu cho thấy sự chênh lệch và phân tán lớn giữa các giá trị
- Một số thuộc tính như Monthly Inhand Salary có phân phối lệch phải. Dữ liệu còn chứa nhiều ngoại lai(outlier)


Nhìn chung, bộ dữ liệu có dấu hiệu nhiễu và ngoại lai, cần có phương án xử lý thích hợp

Cần thực hiện các thao tác xử lý sau:


- Chuyển đổi các trường category về dạng số
- Loại bỏ các giá trị ngoại lai của trường numeric bằng phương pháp IQR
- Xử lý các giá trị null

Sau khi thực hiện làm sạch dữ liệu chỉ còn 39919 bộ dữ liệu, gọn hơn nhiều so với trước


Trình bày và mô tả dữ liệu




(a) Phân bố thu nhập



(b) Phân bố khoản đầu tư



(c) Phân bố tối ưu tín dụng



(d) Số thẻ tín dụng

Giảm chiều dữ liệu


Phương pháp giảm chiều PCA

- Là kĩ thuật giảm chiều dữ liệu sao cho dữ liệu được nhiều thông tin nhất. Thay đổi các thuộc tính ban đầu thành những thuộc tính mới không chồng chéo lên nhau và biểu diễn được nhiều thông tin nhất từ dữ liệu gốc.
- Hoạt động theo cơ chế tìm các trục (thành phần chính) là các vectơ riêng của ma trận hiệp phương sai, sắp xếp theo thứ tự phương sai giảm dần để giữ lại các thành phần quan trọng nhất.

Giảm chiều dữ liệu

Phương pháp giảm chiều PCA

Kết quả PCA trên bộ dữ liệu



Hình: Kết quả chạy PCA

Nhận xét: Không có thành phần chính nào thực sự chiếm ưu thế trong việc giải thích phương sai của dữ liệu

Giảm chiều dữ liệu

Phương pháp giảm chiều LDA


Vì trong bộ dữ liệu này biến mục tiêu có 3 lớp (“Good”, “Standard”, “Poor”), nên LDA chỉ có thể tạo ra tối đa 2 thành phần phân biệt ($3 - 1 = 2$).

LDA hướng đến mục tiêu phân biệt rõ ràng nhất giữa các lớp dữ liệu, và để đạt được điều đó, cần thực hiện hai bước chính sau:

- Tối thiểu within class variances
- Tối đa bình phương khoảng cách giữa hai kỳ vọng còn được gọi là between class variance

Giảm chiều dữ liệu

Phương pháp giảm chiều LDA




Hình: Kết quả chạy LDA

Nhìn chung, kết quả cho thấy mô hình LDA có khả năng phân biệt tốt giữa các nhóm khách hàng dựa trên các đặc trưng đầu vào, đồng thời hai thành phần LD1 và LD2 giữ lại phần lớn thông tin giúp tách biệt các nhóm


Huấn luyện mô hình học máy

Các mô hình được sử dụng



Hình: *

Phân loại KNN (K-Nearest Neighbors): Dự đoán chất lượng điểm tín dụng bằng cách lấy giá trị trung bình của 'K' hàng



Hình: *

Hồi quy Softmax (Softmax Regression): Tìm các siêu phẳng (hyperplane) để phân tách nhiều lớp (category) trong không gian

Huấn luyện mô hình học máy

Các chỉ số đánh giá

Các mô hình huấn luyện sẽ sử dụng các chỉ số sau để đánh giá chất lượng huấn luyện:


- Accuracy score: Tỷ lệ dự đoán đúng trên tổng số mẫu
- Precision score: Tính số True Positive trong tổng số dự đoán Positive
- Recall score: Tính số True Positive trong tổng số giá trị Positive thực tế
- F1 score: Trung bình điều hoà của Recall và Precision

Huấn luyện mô hình học máy

Phân cụm K-Means

Đánh giá mức độ tối ưu số cụm K sử dụng phương pháp Elbow và Silhouette Score

K phân cụm tối ưu: 3




Hình: Đồ thị đánh giá mức tối ưu số cụm K

Huấn luyện mô hình học máy


Phân cụm K-Means

Kết quả đánh giá:

- Độ chính xác (Accuracy): 0.67
- Giá trị Silhouette trung bình: 0.32




Kết quả phân cụm




Ma trận nhầm lẫn

Huấn luyện mô hình học máy


Phân cụm K-Means




Iteration 0



Iteration 3



Iteration 10




Iteration 20

Huấn luyện mô hình học máy

Phân cụm GMM

Thuật toán EM, số cụm $K = 3$



Huấn luyện mô hình học máy

Phân cụm GMM

Nhận xét:

- Các cụm có dạng elip, phù hợp với giả định phân bố Gaussian
- Xuất hiện sự chồng lấn giữa các cụm trên không gian đặc trưng
- GMM mô hình hóa tốt các vùng dữ liệu giao thoa nhờ gán cụm theo xác suất


Phương pháp GMM cho kết quả phân cụm hợp lý, phản ánh cấu trúc xác suất của dữ liệu và phù hợp với bài toán có ranh giới lớp không rõ ràng.

Huấn luyện mô hình học máy

Kết quả K-nn

Thông số tối ưu

- Phương pháp giảm chiều: LDA
- Tỷ lệ train/test: 80/20
- Số láng giềng K: 175



Hình: Kết quả chạy LDA

Bảng: Kết quả Phân loại

Loại dữ liệu	$K = \sqrt{n} = 178$			K tối ưu = 175			Nhận xét
	Acc Train	Acc Test	Chênh lệch	Acc Train	Acc Test	Chênh lệch	
Gốc	62.29	61.91	0.38	62.34	61.71	0.63	Không bị overfit (0.38-0.63)
PCA	67.03	66.43	0.60	67.06	66.47	0.59	
LDA	70.63	70.04	0.59	70.63	70.00	0.63	


Ở mức cơ bản, K-NN có hiệu suất ổn định và nhất quán, là mô hình tham chiếu (baseline) tốt cho bài toán. Tuy nhiên, để tối ưu hiệu quả và an toàn hơn cần phải áp dụng các kỹ thuật tiền xử lý cân bằng dữ liệu hoặc sử dụng mô hình mạnh hơn để cải thiện khả năng phân loại lớp thiểu số.

Huấn luyện mô hình học máy

Kết quả Softmax Regression

Thông số tối ưu

- Phương pháp giảm chiều: LDA
- Tỷ lệ train/test: 80/20



Hình: Kết quả của mô hình

Nhận xét Softmax Regression

Loại dữ liệu	Accuracy Train (%)	Accuracy Test (%)	Chênh lệch
Gốc	65.12	64.85	0.27
PCA	69.43	68.90	0.53
LDA	72.01	71.56	0.45

Bảng: So sánh độ chính xác giữa dữ liệu gốc, PCA và LDA


Softmax Regression cho kết quả khá tốt, đặc biệt khi kết hợp với giảm chiều **LDA** giúp cải thiện độ chính xác lên đến $\approx 70\%$ mà không xảy ra **overfitting** đáng kể. Mô hình này đóng vai trò là một mô hình cơ sở (baseline) hữu ích để so sánh với các phương pháp phức tạp hơn trong học máy..

Huấn luyện mô hình học máy

Kết quả Crammer-Singer SVM

Thông số tối ưu

- Phương pháp giảm chiều: LDA
- Tỷ lệ train/test: 80/20



Nhận xét Crammer-Singer SVM

Bảng: Kết quả đánh giá mô hình với tỷ lệ 80:20

Loại dữ liệu	Accuracy Train	Accuracy Test	Chênh lệch
Gốc	69.54%	69.11%	0.43%
PCA	63.34%	63.18%	0.16%
LDA	71.37%	70.86%	0.51%

Mô hình cho kết quả ở mức khá 70%, độ ổn định cao mà không bị overfitting. Linear SVM phù hợp làm mô hình nền (baseline) cho bài toán phân loại nhiều lớp có kích thước dữ liệu lớn, tuy nhiên hiệu suất có thể được cải thiện thêm bằng kernel phi tuyến hoặc tinh chỉnh tham số.

Mở rộng bài toán sang hồi quy

Từ Softmax Regression đến Regression

- Softmax Regression không chỉ cho nhãn phân loại mà còn cung cấp **xác suất dự đoán** cho từng lớp.
- Thay vì chỉ chọn lớp có xác suất lớn nhất, ta khai thác **giá trị xác suất Softmax** như một biến liên tục.
- Trong bài này, chọn phân lớp **Good** và xây dựng đầu ra hồi quy:

$$y_{\text{reg}} = P(y = \text{Good} \mid x), \quad y_{\text{reg}} \in [0, 1]$$

- Bài toán được chuyển từ **phân loại** sang **hồi quy**.
- Giá trị hồi quy phản ánh **mức độ tin cậy** khách hàng thuộc nhóm tín dụng tốt.

Mô hình hồi quy sử dụng

Regression trên đầu ra Softmax

Hai mô hình hồi quy được áp dụng:

- **Ridge Regression**

- Mô hình hồi quy tuyến tính có hiệu chỉnh chuẩn L_2
- Giúp giảm overfitting khi số chiều dữ liệu lớn
- Ổn định và dễ diễn giải

- **Support Vector Regression (SVR – RBF kernel)**


- Khả năng mô hình hóa quan hệ phi tuyến
- Phù hợp khi xác suất Softmax có phân bố phức tạp

Các mô hình được huấn luyện trên:

- Dữ liệu gốc đã chuẩn hóa
- Dữ liệu giảm chiều còn **1/3 số đặc trưng (PCA)**

Kết quả hồi quy dựa trên Softmax

So sánh Ridge Regression và SVR (RBF)



Hình: So sánh RMSE giữa Ridge Regression và SVR với dữ liệu gốc và PCA 1/3

- RMSE thấp hơn cho thấy mô hình dự đoán xác suất Softmax chính xác hơn.

• SVR (RBF) có xu hướng hoạt động tốt hơn khi dữ liệu được giảm

Nhận xét mở rộng sang hồi quy

Đánh giá kết quả thực nghiệm

- Ridge Regression cho kết quả ổn định giữa các tỉ lệ train/test.
- SVR (RBF) cho sai số thấp hơn trong một số trường hợp nhờ khả năng mô hình hóa phi tuyến.
- Giảm chiều bằng PCA giúp:
 - Giảm nhiễu
 - Tăng khả năng tổng quát hóa
 - Đặc biệt hiệu quả với SVR
- Kết quả hồi quy cho thấy xác suất Softmax có thể được sử dụng như một **thước đo liên tục** để đánh giá chất lượng tín dụng.

Cách tiếp cận này giúp mở rộng bài toán phân loại sang bài toán đánh giá và xếp hạng tín dụng mềm (soft decision).

10.1 Mô hình SVR

10.1.1 Ý tưởng

- Bài toán phân loại ban đầu được chuyển đổi sang bài toán hồi quy bằng cách thay đổi hàm mục tiêu của mô hình SVM.
- Thay vì tối ưu hàm mất mát cho phân loại, mô hình được xây dựng dưới dạng *Support Vector Regression (SVR)*.
- Mục tiêu là tìm một hàm hồi quy sao cho sai lệch giữa giá trị dự đoán và giá trị thực của biến mục tiêu được tối thiểu hóa trong một ngưỡng cho phép.

10.1 Mô hình SVR (tiếp)

10.1.2 Hàm mục tiêu

- SVR xây dựng một hàm hồi quy:

$$f(x) = \mathbf{w}^T x + b$$

- Sao cho sai lệch giữa giá trị dự đoán và giá trị thực không vượt quá một ngưỡng ε đối với phần lớn mẫu dữ liệu.
- Hàm mục tiêu nhằm tối thiểu hóa độ phức tạp của mô hình (thông qua chuẩn $\|\mathbf{w}\|^2$), đồng thời phạt các sai lệch vượt quá ngưỡng ε .

Bài toán tối ưu của SVR

Bài toán tối ưu của SVR có dạng:

$$\min_{\mathbf{w}, b, \xi, \xi^*} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N (\xi_i + \xi_i^*)$$

với các ràng buộc:


$$\begin{cases} y_i - (\mathbf{w}^T x_i + b) \leq \varepsilon + \xi_i, \\ (\mathbf{w}^T x_i + b) - y_i \leq \varepsilon + \xi_i^*, \\ \xi_i, \xi_i^* \geq 0, \quad i = 1, \dots, N. \end{cases}$$

Chuyển sang bài toán hồi quy

Mô hình SVR

Thông số tối ưu

- Phương pháp giảm chiều: LDA
- Tỷ lệ train/test: 70/30



Chuyển sang bài toán hồi quy

Đánh giá SVR

Bảng: Kết quả đánh giá mô hình với tỷ lệ 70:30

Loại dữ liệu	MSE	RMSE	R^2
Gốc	0.4059	0.6371	0.0955
PCA	0.3359	0.5796	0.2515
LDA	0.3041	0.5514	0.3225

- R^2 thấp (< 0.35): Khả năng giải thích phương sai của mô hình còn hạn chế.
- Sai số còn cao: MSE/RMSE giảm nhưng độ chính xác chưa đạt yêu cầu thực tiễn.

⇒ **Kết luận: SVR chưa hiệu quả, không cải thiện rõ rệt hiệu suất, chủ yếu có ý nghĩa phương pháp.**

Kết quả thực nghiệm

- Mô hình đã đạt độ chính xác trung bình $\approx 70 - 74\%$, thể hiện khả năng học được các đặc trưng cơ bản của dữ liệu.
- Việc áp dụng PCA và LDA giúp cải thiện đáng kể hiệu quả mô hình so với dữ liệu gốc, chứng tỏ các kỹ thuật giảm chiều dữ liệu mang lại lợi ích rõ rệt.
- Mức chênh lệch nhỏ giữa Train Accuracy và Test Accuracy cho thấy mô hình tổng quát hóa khá tốt, không bị overfitting nghiêm trọng.

Kết thúc!

Xin chân thành cảm ơn thầy/cô và các bạn đã lắng nghe.

Đường link Drive đến bài báo cáo và chương trình nguồn:

<https://drive.google.com/drive/folders/13HVQrcZefAPxPL46aMzo9s>